

ZaDANO



структура данных

**~500 тысяч
аварий**


**80
переменных**

**Что за данные?
ДТП со всех регионов
РФ за 2015-2024 год**


**База данных не имеет
пропусков**

Используемые переменные

- Средний стаж виновных водителей
- Количество транспортных средств, участвовавших в ДТП



Подготовка данных




по 1.5 межквартильного размаха
**Удалены выбросы
среднего стажа
виновных водителей**

также удалены аварии с рангами
дорог типа 'Не указано'

**Удалено 10% данных
57734 аварий**

Подготовка данных




11 лет
медианный стаж

14 лет
средний стаж

11 лет
среднеквадратичное
отклонение

Подготовка данных



2
наиболее частое количество ТС
участвовавших в ДТП

Предварительный анализ

Пол	1.00	0.02	0.02	0.03	0.03	0.01	0.06
Выходной	0.02	1.00	0.01	0.02	0.02	0.01	0.02
Погода	0.02	0.01	1.00	0.03	0.02	0.06	0.11
Год	0.03	0.02	0.03	1.00	0.09	0.06	0.03
Ранг	0.03	0.02	0.02	0.09	1.00	0.04	0.11
встречка	0.01	0.01	0.06	0.06	0.04	1.00	0.38
маневр	0.06	0.02	0.11	0.03	0.11	0.38	1.00
	Пол	Выходной	Погода	Год	Ранг	встречка	маневр

**Матрица корреляций V Крамера
между категориальными и
бинарными переменными**

**Наблюдается небольшая корреляция между
выездом на встречу и совершением
неверного маневра, что логично**


Предварительный анализ

Все коэффициенты
корреляции статистически
значимы ($p\text{-value} < 0.05$)

Структуру аварий в РФ за 2015-2024 год

	Календарный год корреляция по Спирмену	
Количество аварий	-0.91	Снизилось число аварий
Стаж виновных	0.99	Вырос средний стаж
мин. возраст авто	0.96	Вырос минимальный возраст авто
Средняя тяжесть	-0.89	Снизилась тяжесть аварий

Предварительный анализ



Выросло
количество аварий с 3-4 ТС

0.51

Корреляция по Спирмену (p-value < 0.05)

СНИЗИЛОСЬ
количество аварий с 1-2 ТС

-0.92

Корреляция по Спирмену (p-value < 0.05)

Предварительный анализ


Бинарная переменная является ли авария
массовой

0

авария с 1-2 ТС


1

авария с 3-4 ТС



распределение по флагу, массовая авария или нет

Предварительный анализ



**График средней доли
аварий с 3-4 ТС по
стажу водителей,
среди всех аварий**


Исследовательский вопрос

Что влияет на массовость аварии?

Гипотеза

**Доля аварий с числом ТС 3-4, квадратично
зависит от среднего стажа виновных
водителей в аварии**

Механизм



Математическая модель

Для доказательства нашей гипотезы используем логистическую регрессию с целевой переменной

Массовая авария или нет

Математическая модель

уравнение логистической регрессии

$$y = \frac{1}{1 + e^{-X}}, \text{ где } X = \beta_0 + \beta_1 \times \text{стаж} + \beta_2 \times \text{стаж}^2 + \beta_k \times K$$

вектор коэффициентов для
контрольных переменных




вектор контрольных
переменных



модель БЕЗ контрольных переменных

	coef	p-value
intercept	-2.17	0.00
стаж	0.047	0.00
стаж ²	-0.00008	0.00



Коэффициенты модели при переменных стат
значимы

Математическая модель


добавляем контрольные переменные:
о водителе и времени

	coef
intercept	-205
стаж	0.037
стаж ²	-0.0007
год	0.10
выходной	-0.11
пол	-0.17
время суток	-0.07
маневр	1.17
встречная полоса	0.67
жилые объекты	-0.23
дорожная инфраструктура	0.07
социальная инфраструктура	0.04
транспортная инфраструктура	-0.07
другие места	-0.6
дорога местного назначения	-0.4
Федеральная дорога	0.81
Частная дорога	0.40

**Все коэффициенты
статистически значимы
p-value < 0.05**

Проверка на устойчивость


Многократно будем создавать бутстреп выборки и рассчитывать коэффициенты, что бы построить доверительные интервалы



Проверка на устойчивость


Доверительные интервалы не включают 0, значит коэффициенты статистически значимы на уровне значимости $\alpha = 0.05$

Распределение коэффициента guilty_exp_avg_2



Проверка на устойчивость

СРАВНЕНИЕ ЗАВИСИМОСТЕЙ ПО ФЕДЕРАЛЬНЫМ ОКРУГАМ
(контрольные переменные зафиксированы на средних значениях)



Модель устойчива
относительно округов

	стаж	стаж ²
все округа	0.037	-0.0007
СФО	0.039	-0.0007
СКФО	0.025	-0.0004
СЗФО	0.04	-0.0008
ПФО	0.037	-0.0007
ДФО	0.038	-0.0008
ЦВО	0.04	-0.0008
УФО	0.027	-0.0005
ЮФО	0.04	-0.0008

все коэффициенты при переменных
статистически значимы ($p\text{-value} < 0.05$)

Результат

**Гипотеза подтвердилась и прошла
проверку на устойчивость**



**При среднем стаже (25–30 лет)
достигается максимум вероятности
массовой аварии, при возникновении
аварии**

Сравнения с другими исследованиями

”

**The Impact of Aging Drivers and Vehicles on the Injury
Severity of Crash Victims**


**Влияние возраста водителей и транспортных
средств на тяжесть аварий**

<https://clck.ru/3QrSzB>

”

**В данном исследовании схожая
(квадратичная) зависимость между возрастом
водителя попавшем в аварию и тяжестью
этого ДТП**

Альтернативный механизм



Источники:

2. Exploring the relationships between drivers' familiarity and two-lane rural road accidents. A multi-level study (2017)

3. Using naturalistic driving data to better understand the driving exposure and patterns of older drivers (2018)

Policy implication

Использовать средний стаж виновных водителей как один из параметров при расчёте рисков для страховых компаний (к примеру изменить тарифы)

Возможность введения VR-тренажеров

Организация курсов переподготовки для группы риска, где будут разбираться ситуации, потенциально опасные для создания массовых аварий

подобное реализовано в Канаде

Ограничения

Перспективы
Анализа



**Ограничены факторы, описывающие
работу ГибДД**
(отсутствуют: наличие камер, дежурство патруля ГибДД,
на участках дороги)



**Анализ мер,
уменьшающих
аварийность**

**В базе отсутствуют данные о водителях
(образование, возраст и тд.)**



**Анализ совместного
влияния стажа и
возраста для выявления
новых закономерностей**

В базе нет данных о ремонтных работах




**Анализ влияния
ремонтных работ на
аварийность на улицах
рядом с местом
перекрытия**


Команда




Большаков Андрей




Труньков Евгений



Добрынина Маргарита



Баранов Дмитрий



Люков Александр

Приложение

ТС	1.00	0.50	0.07	0.14	-0.05	0.04	-0.83	-0.08	0.07
человек	0.50	1.00	0.21	0.67	0.01	0.03	-0.43	-0.08	0.00
погибших	0.07	0.21	1.00	-0.16	0.10	-0.01	-0.02	0.04	-0.01
раненых	0.14	0.67	-0.16	1.00	0.02	0.02	-0.18	-0.04	-0.01
пьяных	-0.05	0.01	0.10	0.02	1.00	-0.05	0.03	0.14	-0.15
возраст ТС	0.04	0.03	-0.01	0.02	-0.05	1.00	-0.04	-0.05	0.11
доля	-0.83	-0.43	-0.02	-0.18	0.03	-0.04	1.00	0.06	-0.04
стаж	-0.08	-0.08	0.04	-0.04	0.14	-0.05	0.06	1.00	0.07
год	0.07	0.00	-0.01	-0.01	-0.15	0.11	-0.04	0.07	1.00
	ТС	человек	погибших	раненых	пьяных	возраст ТС	доля	стаж	год

Матрица корреляций Пирсона
для количественных
переменных


Сильных не тривиальных корреляций нет

Проверка возможности использования logit модели

feature	VIF
const	501733
guilty_exp_avg	8.62
guilty_exp_avg_2	8.47
maneuver_violation	1.34
wrong_way	1.29
ROAD_INFRSTRCT	1.07
Федеральная	1.07
LIVING_OBJ	1.05
YEAR	1.05
female_driver	1.05
Местного значения	1.05
TRANSPORT_OBJ	1.05
SOCIAL_OBJ	1.04
is_NIGHT	1.04
is_WEEKEND	1.01
Другие места	1.00
Частная	1.00

- Таргет - бинарная переменная
- Наблюдения не зависимы
- При исследуемом показателе мультиколлинеарности нет, она есть лишь при age и age^2 , что логично:

- У переменной среднего опыта виновных водителей наблюдается четкая квадратная зависимость с долей аварий с 3-4 ТС, поэтому что бы учесть это, мы также добавили стаж в квадрате



Проверка возможности использования logit модели

	Параметр	HC0 (β)	HC0 (p)	HC1 (β)	HC1 (p)	HC2 (β)	HC2 (p)	HC3 (β)	HC3 (p)
0	const	-205.1308	0.0000	-205.1308	0.0000	-205.1308	0.0000	-205.1308	0.0000
1	guilty_exp_avg	0.0369	0.0000	0.0369	0.0000	0.0369	0.0000	0.0369	0.0000
2	guilty_exp_avg_2	-0.0007	0.0000	-0.0007	0.0000	-0.0007	0.0000	-0.0007	0.0000
3	YEAR	0.1000	0.0000	0.1000	0.0000	0.1000	0.0000	0.1000	0.0000
4	is_WEEKEND	-0.1154	0.0000	-0.1154	0.0000	-0.1154	0.0000	-0.1154	0.0000
5	female_driver	0.1782	0.0000	0.1782	0.0000	0.1782	0.0000	0.1782	0.0000
6	is_NIGHT	-0.0783	0.0000	-0.0783	0.0000	-0.0783	0.0000	-0.0783	0.0000
7	maneuver_violation	1.1671	0.0000	1.1671	0.0000	1.1671	0.0000	1.1671	0.0000
8	wrong_way	0.6715	0.0000	0.6715	0.0000	0.6715	0.0000	0.6715	0.0000
9	adj_objects_interpretable_LIVING_OBJ	-0.2373	0.0000	-0.2373	0.0000	-0.2373	0.0000	-0.2373	0.0000
10	adj_objects_interpretable_ROAD_INFSTRCT	0.0779	0.0000	0.0779	0.0000	0.0779	0.0000	0.0779	0.0000
11	adj_objects_interpretable_SOCIAL_OBJ	0.0431	0.0254	0.0431	0.0254	0.0431	0.0254	0.0431	0.0254
12	adj_objects_interpretable_TRANSPORT_OBJ	-0.0701	0.0001	-0.0701	0.0001	-0.0701	0.0001	-0.0701	0.0001
13	road_rank_cat_Другие места	-0.5997	0.0000	-0.5997	0.0000	-0.5997	0.0000	-0.5997	0.0000
14	road_rank_cat_Местного значения	-0.4117	0.0000	-0.4117	0.0000	-0.4117	0.0000	-0.4117	0.0000
15	road_rank_cat_Федеральная	0.8176	0.0000	0.8176	0.0000	0.8176	0.0000	0.8176	0.0000
16	road_rank_cat_Частная	0.4083	0.0000	0.4083	0.0000	0.4083	0.0000	0.4083	0.0000

**Мы подозреваем наличие
гетероскедастичности,
поэтому посмотрим на разные
виды робастых ошибок.**



**При изменении типа робастых
ошибок, стат значимость, как
и знак не поменялись**

Выбор контрольных переменных



Добавляем в регрессию как контрольную переменную

female_driver (clck.ru/3QrPz6)

YEAR - чтобы удалить тренд

is_NIGHT и **WEEKDAY** - тест разных трафиков на дорогах

Маневры повышают шанс массовой аварии



	был маневр	не было маневра
3-4 TC	248901	107442
1-2 TC	28735	32619

Используем Хи-квадрат Пирсона
Хи-квадрат: 12437.29
p-value: 0.0


При совершенном маневре доля массовой аварии больше

При этом при наличии маневра доля немассовых аварий (1-2 машины) меньше , чем при его отсутствии

Следовательно, совершенный маневр повышает шанс массовой аварии


Приложение

Масштабные аварии статистически значимо более тяжелые чем не масштабные



Сравним с помощью критерия Манна-Уитни группы ($p\text{-value} < 0.05$)


Маржинальный эффект



$$y' = \sigma(x)(1 - \sigma(x)) \times (\beta_1 + 2\beta_2 x)$$

**Пример: при изменении стажа с 10 до 20 лет
вероятность, что произошедшая авария будет
массовой повысится на 3,09%**

Приложение




СНИЗИЛОСЬ
количество аварий в РФ

-0.91

Корреляция по Спирмену (p-value < 0.01)

Приложение




Вырос
средний стаж виновных
водителей в РФ

0.99

Корреляция по Спирмену ($p\text{-value} < 0.01$)

Приложение




Вырос
средний минимальный возраст
авто в РФ

0.96

Корреляция по Спирмену (p-value < 0.01)

Приложение




проверено на данных*

Снизилась
средняя тяжесть аварий в РФ

-0.89

Корреляция по Спирмену (p-value < 0.01)

Приложение




**матрица корреляций
для структуры аварий в
РФ**

Проверка возможности использования logit модели

	Параметр	HC0 (β)	HC0 (SE)	HC0 (p)	HC1 (β)	HC1 (SE)	HC1 (p)	HC2 (β)	HC2 (SE)	HC2 (p)	HC3 (β)	HC3 (SE)	HC3 (p)
0	const	-205.1308	3.1606	0.0000	-205.1308	3.1606	0.0000	-205.1308	3.1606	0.0000	-205.1308	3.1606	0.0000
1	guilty_exp_avg	0.0369	0.0012	0.0000	0.0369	0.0012	0.0000	0.0369	0.0012	0.0000	0.0369	0.0012	0.0000
2	guilty_exp_avg_2	-0.0007	0.0000	0.0000	-0.0007	0.0000	0.0000	-0.0007	0.0000	0.0000	-0.0007	0.0000	0.0000
3	YEAR	0.1000	0.0016	0.0000	0.1000	0.0016	0.0000	0.1000	0.0016	0.0000	0.1000	0.0016	0.0000
4	is_WEEKEND	-0.1154	0.0099	0.0000	-0.1154	0.0099	0.0000	-0.1154	0.0099	0.0000	-0.1154	0.0099	0.0000
5	female_driver	0.1782	0.0114	0.0000	0.1782	0.0114	0.0000	0.1782	0.0114	0.0000	0.1782	0.0114	0.0000
6	is_NIGHT	-0.0783	0.0129	0.0000	-0.0783	0.0129	0.0000	-0.0783	0.0129	0.0000	-0.0783	0.0129	0.0000
7	maneuver_violation	1.1671	0.0106	0.0000	1.1671	0.0106	0.0000	1.1671	0.0106	0.0000	1.1671	0.0106	0.0000
8	wrong_way	0.6715	0.0108	0.0000	0.6715	0.0108	0.0000	0.6715	0.0108	0.0000	0.6715	0.0108	0.0000
9	adj_objects_interpretable_LIVING_OBJ	-0.2373	0.0167	0.0000	-0.2373	0.0167	0.0000	-0.2373	0.0167	0.0000	-0.2373	0.0167	0.0000
10	adj_objects_interpretable_ROAD_INFSTRCT	0.0779	0.0139	0.0000	0.0779	0.0139	0.0000	0.0779	0.0139	0.0000	0.0779	0.0139	0.0000
11	adj_objects_interpretable_SOCIAL_OBJ	0.0431	0.0193	0.0254	0.0431	0.0193	0.0254	0.0431	0.0193	0.0254	0.0431	0.0193	0.0254
12	adj_objects_interpretable_TRANSPORT_OBJ	-0.0701	0.0185	0.0001	-0.0701	0.0185	0.0001	-0.0701	0.0185	0.0001	-0.0701	0.0185	0.0001
13	road_rank_cat_Другие места	-0.5997	0.1476	0.0000	-0.5997	0.1476	0.0000	-0.5997	0.1476	0.0000	-0.5997	0.1476	0.0000
14	road_rank_cat_Местного значения	-0.4117	0.0256	0.0000	-0.4117	0.0256	0.0000	-0.4117	0.0256	0.0000	-0.4117	0.0256	0.0000
15	road_rank_cat_Федеральная	0.8176	0.0094	0.0000	0.8176	0.0094	0.0000	0.8176	0.0094	0.0000	0.8176	0.0094	0.0000
16	road_rank_cat_Частная	0.4083	0.0924	0.0000	0.4083	0.0924	0.0000	0.4083	0.0924	0.0000	0.4083	0.0924	0.0000

**Мы подозреваем наличие
гетероскедастичности,
поэтому посмотрим на разные
виды робастных ошибок.**



**При изменении типа робастных
ошибок, стат значимость, как
и знак не поменялись**

+ значение ошибки